

## Raport: Milestone 1

**Projekt:** Analiza procesu produkcji figur szachowych

### 1. Opis zbioru danych i jego kontekstu

Analizowany zbiór danych pochodzi ze środowiska CPEE i rejestruje proces produkcji 9 aluminiowych figur szachowych (wież). System loguje dane pochodzące z trzech głównych źródeł (maszyn):

- **EMCO MT45 Lathe:** Tokarka CNC odpowiedzialna za obróbkę aluminium.
- **ABB IRB-2600:** Ramię robotyczne zajmujące się manipulacją i przenoszeniem detalu.
- **Keyence LS-7000:** Mikrometr optyczny / czujnik wykonujący końcowy pomiar i kontrolę jakości.

Z perspektywy biznesowej proces obejmuje **9 instancji** (produkcja 9 pojedynczych figur, oznaczonych jako Turm Single). Jednakże na poziomie technicznym log systemowy jest znacznie bardziej szczegółowy i rozbija się na **234 instancje (cases)**, obejmując sub-procesy i zdarzenia poboczne. Zbiór zawiera łącznie **10 557 surowych zdarzeń (events)** zarejestrowanych w 235 poprawnych plikach.

### 2. Identyfikacja kluczowych atrybutów logu zdarzeń

Dane posiadają pierwotnie strukturę zagnieżdżoną (m.in. pola concept:\*, cpee:\*, data), z której z powodzeniem wyodrębniono atrybuty niezbędne do Process Miningu:

- **case\_id:** Główny identyfikator procesu.
- **activity:** Nazwa wykonywanej czynności. Brak pustych wartości.
- **lifecycle:** Faza cyklu życia zdarzenia (np. start, complete, unknown).
- **timestamp:** Znacznik czasu zdarzenia.
- **resource:** Identyfikator maszyny wykonującej zadanie.

### 3. Analiza jakości danych

Jakość surowych danych wymagała wstępnego oczyszczenia ze względu na naturę logów maszynowych.

- **Brakujące wartości:** Odnotowano znaczne braki w dwóch kolumnach. Atrybut resource jest pusty w **74,38%** przypadków (7852 zdarzenia). Znaczników czasu (timestamp) brakuje dla **10,39%** zdarzeń (1097 przypadków).
- **Duplikaty:** Identyfikacja zduplikowanych wpisów wykazała 1168 powtórzonych zdarzeń, co stanowi **11,06%** całego logu.

- **Znaczniki czasu:** Daty wymagały konwersji ze stringów do obiektów datetime. Nie odnotowano niespójnych logów.
- **Niejednorodność zdarzeń:** Duża część zdarzeń ma charakter czysto techniczny lub systemowy (fazy unknown - 7046 razy). Wymaga to późniejszego oddzielenia logu operacyjnego od technicznego.

#### 4. Eksploracyjna Analiza Danych (EDA) i Podstawowe Statystyki

Po oczyszczeniu, zbiór gotowy do analizy składa się z **64 unikalnych aktywności**.

**Statystyki dla poszczególnych instancji (cases):**

- **Średnia liczba zdarzeń na instancję:** ~45,11
- **Mediana:** 31 zdarzeń
- **Odchylenie standardowe:** ~33,90
- **Minimum / Maksimum:** od 11 do aż 175 zdarzeń w najdłuższym przypadku.

Tak duża rozpiętość długości przypadków wynika bezpośrednio z obecności zdarzeń technicznych oraz pętli pomiarowych/naprawczych.

#### 5. Modele BPMN

W analizowanym zbiorze danych nie załączono gotowych modeli BPMN (np. plików .bpmn). Przebieg procesu jest w całości rekonstruowany na podstawie płaskiego logu zdarzeń generowanego przez sensory (z plików .xes.yaml). Rekonstrukcja wizualna ścieżek procesu będzie możliwa dopiero po zastosowaniu algorytmów odkrywania procesów (np. Alpha Miner lub Heuristic Miner) w kolejnych etapach projektu.

#### Podsumowanie

Zbiór "Nine Rooks" stanowi kompletny zapis procesu cyber-fizycznego. Głównym wyzwaniem analitycznym, zidentyfikowanym w Milestone 1, jest potrzeba atrybuowania brakujących zasobów maszynowych (resource) na podstawie kontekstu zadań oraz filtracja zdarzeń technicznych, które zaburzają widok biznesowy produkcji figury szachowej. Zbiór jest jednak wystarczająco spójny (posiada poprawne case\_id oraz activity), by stanowić fundament do modelowania Process Mining.