

|                                                                                   |                                                                     |                        |
|-----------------------------------------------------------------------------------|---------------------------------------------------------------------|------------------------|
|  | Imię i nazwisko:                                                    | Grupa Laboratoryjna: 1 |
|                                                                                   | Łukasz Florek,<br>Konrad Czerniej                                   | Raport: Milestone 2    |
|                                                                                   | <b>Przedmiot:</b><br><br>Modelowanie i analiza procesów biznesowych |                        |
| Wydział i kierunek: EAliIB – AiR (specj. ISZ)                                     | Temat: XES Chess Pieces Production                                  |                        |

## 1. Wprowadzenie i Cel Analizy

Celem drugiego etapu projektu była eksploracja danych telemetrycznych robota ABB IRB-2600 i transformacja ciągłego strumienia położeń  $(X, Y, Z)$  w zdefiniowane, dyskretne stany procesowe. Ponieważ surowe logi maszyny nie posiadają znaczników informujących o aktualnie wykonywanej czynności przestrzennej, konieczne było wykorzystanie nienadzorowanego uczenia maszynowego (Unsupervised Learning) do segmentacji trajektorii. Etap ten obejmował inżynierię cech, redukcję wymiarowości oraz ewaluację dwóch algorytmów klasteryzacji: K-Means oraz DBSCAN.

## 2. Przygotowanie, Czyszczenie i Normalizacja Danych


Zbiór danych został poddany ustrukturyzowaniu przed aplikacją modeli:

- **Próbkowanie czasowe (Resampling):** Ciągłe odczyty ujednolicono do rozdzielczości 100 ms, co pozwoliło na synchronizację znaczników czasu i eliminację duplikatów.
- **Rozszerzenie przestrzeni cech:** Bazowe współrzędne rozszerzono o pierwszą pochodną położeń  $(dX, dY, dZ)$ , reprezentującą wektor prędkości. Włączono również binarne statusy maszyn (Turning, Measuring, GripperEngaged).
- **Skalowanie:** Zastosowano standaryzację wariancji (StandardScaler), zapewniając równy wpływ każdej z cech na metryki dystansu w algorytmach klasteryzujących.

Zastosowano RobustScaler, który zminimalizował wpływ nagłych pików prędkości (outlierów kinematycznych) na wyznaczanie klastrów.

### 3. Redukcja Wymiarowości (PCA)

W celu analizy struktury danych oraz usunięcia współliniowości cech, przeprowadzono Analizę Głównych Składowych (PCA).




Rys.1 wykres osypiska oraz profil skumulowanej wariancji PCA

**Wniosek analityczny:** Jak pokazuje Wykres Osypiska, pierwsza składowa główna (PCA1) wyjaśnia 30% wariancji, a druga (PCA2) niecałe 19%. Wykorzystanie dwóch pierwszych składowych pozwala na rzutowanie 49% zmienności na płaszczyznę 2D w celach wizualizacyjnych. Docelowa klasteryzacja została jednak przeprowadzona na zredukowanej przestrzeni 6 pierwszych składowych głównych. Zgodnie z wyznaczonym progiem inżynierskim, te 6 komponentów wystarczyło do wyjaśnienia ponad 80% całkowitej wariancji układu. Pozwoliło to na redukcję szumu wymiarowego przy zachowaniu detali kinematyki maszyny.

#### 4. Analiza Czułości i Porażka Modelu DBSCAN

Wstępnym założeniem było wykorzystanie algorytmu gęstościowego DBSCAN. Założono, że postoje robota w stacjach wygenerują gęste skupiska punktów, a ruchy między nimi zostaną uznane za szum. Przeprowadzono analizę czułości algorytmu na parametr `min_samples`.




Rys.2 Analiza czułości parametrów gęstościowych `min_samples`

**Ewaluacja algorytmu:** Model DBSCAN w kontekście danych z ciągłej trajektorii robota okazał się nieużyteczny dla celów Process Miningu. Wraz ze wzrostem rygorystyczności parametru `min_samples`, algorytm klasyfikował niemal 50% wszystkich punktów układu jako szum / outliersy (klaster -1). DBSCAN zidentyfikował wyłącznie stany spoczynku maszyny, gubiąc informacje o ścieżkach transferowych, które są krytyczne dla rekonstrukcji przepływu procesu. Z tego względu model DBSCAN został ostatecznie odrzucony.

## 5. Porównanie Modeli w Zredukowanej Przestrzeni PCA

Decyzję o odrzuceniu DBSCAN i przyjęciu modelu K-Means (optymalizowanego metodą Łokcia do  $k = 9$ ) potwierdza projekcja klastrów na przestrzeń 2D.




Rys.3 Porównanie metod klasteryzacji w przestrzeni PCA

Model K-Means (Wykres A) dokonuje podziału przestrzeni w oparciu o dystans (komórki Voronoia). Dzięki temu każdy punkt został przypisany do konkretnej strefy. Model DBSCAN (Wykres B) rozbił przestrzeń, klasyfikując większość punktów tranzytowych jako szum (kolor czerwony), co uniemożliwia zbudowanie na tej podstawie grafu przejść.

## 6. Analiza Anatomiczna Trajektorii 3D

Nałożenie klastrów modelu K-Means na zrekonstruowany model przestrzenny robota pozwoliło na nadanie abstrakcyjnym grupom konkretnego sensu biznesowego.




Rys.4 Analiza anatomiczna trajektorii

Dzięki specyfice K-Means, uzyskano ciągłą i w pełni pokrywającą przestrzeń segmentację stref roboczych. Zidentyfikowano precyzyjne fazy ruchu, takie jak:

- **Odkładanie figury na tacę (Klaster 2):** Wyraźny wzorec w kształcie grzebienia obrazujący odkładanie detalu w 9 różnych slotach magazynu.
- **Ruch po górnym łuku (Klaster 5):** Górna trajektoria omijająca elementy kolizyjne.
- **Transport - Węzeł główny (Klaster 0):** Główna oś logistyczna, przez którą robot przemieszcza się między tokarką a stacją pomiarową.

## 7. Analiza Relacji Między Zdarzeniami (Macierze Tranzycji)

Skompresowano 100-milisekundowe ramki czasowe w celu wyodrębnienia dyskretnych przejść pomiędzy zidentyfikowanymi strefami (klastrami).




Rys.5 macierze tranzycji procesu po kompresji czasowej

Macierze obrazują przepływ sterowania. Macierz dla K-Means (niebieska) wykazuje deterministyczny charakter procesu. Relacje nie są losowe, z każdej strefy istnieje dominujące prawdopodobieństwo przejścia do konkretnej strefy następnej (np. z klastra 7 przechodzi się w 89,5% przypadków do klastra 5). Z kolei macierz dla DBSCAN (pomarańczowa) potwierdza jego dysfunkcyjność – ogromna większość operacji kończy się przejściem do stanu "-1" (Szum).

## 8. Wykrywanie Anomalii (Zależności Czasowo-Przestrzenne)

Dzięki zagregowaniu danych systemowych i telemetrii, wykryto istotną korelację kinematyczną wpływającą na wydajność gniazda.



Rys.6 Głębokość Z vs czas take out

**Identyfikacja anomalii:** Istnieje silna korelacja ( $R \approx -0.53$ ) między głębokością wjazdu ramienia robota w oś Z maszyny a czasem operacji wypychania detalu. Dla najdłuższych cykli produkcyjnych robot musiał zanurkować do najniższej wartości (ok. 128 mm). Oznacza to anomalię technologiczną – trudności z wydobyciem wyprodukowanego detalu z uchwytu tokarki bezpośrednio rzutują na wydłużenie cyklu w systemie.

## **9. Podsumowanie**

W ramach Milestone 2 przeprowadzono ewaluację modeli klasteryzacji dla danych IoT. Wykryto, że algorytmy oparte na gęstości (DBSCAN) nie sprawdzają się w modelowaniu ciągłych trajektorii robotów ze względu na generowanie nadmiernej ilości szumu (ponad 40%). Jako docelowy model wybrano algorytm dystansowy K-Means. Pozwolił on na segmentację przestrzeni roboczej maszyny na 9 logicznych klastrów (np. dojazd, odkładanie na tacę). Utworzony w ten sposób słownik dyskretnych przejść przestrzennych stanowi fundament pod aplikację algorytmów klasycznego Process Miningu w Milestone 3.